M3D-RefSeg: Text-Guided 3D Medical Image Segmentation — 项目完整记录

1. 项目概述

任务：给定一个3D CT体积和一段放射科自由文本描述，分割出对应的3D区域（Referring Expression Segmentation）。

数据集：M3D-RefSeg

- 208个病例，784个标注区域
- 数据格式：`ct.npy` (1, 32, 256, 256) float32 [0,1]，`mask.npy` (1, 32, 256, 256)，`text.json` {mask_id: 描述}
- 文本为详细的放射科发现，例如：
  - "右侧腹股沟区不规则肿块，增强扫描边缘强化"
  - "双肺多发圆形透亮影，考虑双侧肺气肿"

硬件环境：

- GPU: NVIDIA RTX 4070, 12GB VRAM
- OS: Windows 11
- PyTorch 2.11.0+cu126, CUDA 13.0

仓库：GitHub (public)，MedSAM 和 MedCLIP-SAMv2 作为子目录克隆到项目中。

---

2. 实验总览

全部实验结果汇总

编号	方法	Mean Dice	Mean IoU	Dice≥0.5	说明
Exp1	SAM ViT-B (oracle bbox)	0.4496	0.3420	40.5%	原始SAM权重，50 cases
Exp2	**MedSAM fine-tuned (oracle bbox)**	**0.5221**	**0.4046**	**47.3%**	Fine-tuned权重，30 cases
Exp3	MedSAM + 推理tricks	0.4986~0.5150	—	—	multimask/refine/cc3d均无提升
Exp4	TF-IDF文本检索 → bbox → MedSAM	0.0308	—	0%	纯文本检索，30 cases
Exp5	Prompt Compiler (解析+atlas+检索)	0.0235	—	0%	结构化规则，30 cases
Exp6	MedCLIP-SAMv2 (无slice过滤)	0.0073	0.0038	0%	BiomedCLIP saliency→bbox→MedSAM，3 cases

编号	方法	Mean Dice	Mean IoU	Dice≥0.5	说明
Exp7	**MedCLIP-SAMv2 (有slice过滤)**	**0.0284**	**0.0156**	**0%**	加入聚焦度排序过滤，5 cases

核心结论：Oracle bbox Dice=0.52 vs 所有text-guided方法 Dice≈0.02~0.03，差距约20倍。瓶颈不在分割模型，而在**如何从文本定位到空间位置。**

---

3. 实验详情

Exp1 & Exp2: MedSAM Oracle Bounding Box 基线

脚本：`inference_medsam_refseg.py`

流程：

1. 遍历CT volume的32个slice
2. 对每个目标区域，从ground-truth mask提取2D bounding box（oracle bbox, margin=5px）
3. Slice resize到1024×1024，ViT-B编码器fp16编码
4. Bbox prompt送入mask decoder，获取binary mask
5. 堆叠2D预测为3D，计算Dice/IoU

结果对比：

权重	Mean Dice	Mean IoU	Dice≥0.5
SAM ViT-B 原始 (50 cases)	0.4496	0.3420	40.5%
MedSAM fine-tuned (30 cases)	**0.5221**	**0.4046**	**47.3%**

MedSAM fine-tuned权重比原始SAM提升约7个百分点。

Exp3: 推理时优化尝试

脚本：`inference_medsam_improved.py`（支持 `--tricks multimask,refine,cc3d,tta`）

配置	Mean Dice	说明
Baseline (single mask)	**0.5221**	最优
Multi-mask (IoU head选择)	0.5150	IoU head不可靠
Multi-mask + 迭代refinement	0.5063	放大初始过分割
Multi-mask + refinement + CC3D	0.4986	伤害散在正确预测
CC3D only	0.5074	轻微下降

结论：所有tricks均无法提升Mean Dice，baseline即最优。

Exp4: TF-IDF 文本检索 → bbox → MedSAM

脚本：`inference_medsam_retrieval.py`

方法：

1. 用TF-IDF (max_features=5000, ngram_range=(1,2)) 对784条描述建立向量
2. Leave-one-case-out检索top-3相似描述
3. 用检索到的归一化bbox加权平均作为MedSAM prompt

结果：Mean Dice = **0.0308**，53/91 targets Dice=0

失败原因：词袋相似度无法提供空间定位。不同患者的同一解剖结构在npy中占据不同像素坐标（因裁剪/缩放不同）。

Exp5: Prompt Compiler（结构化解析 + Atlas先验 + 检索）

脚本：`experiments/scripts/inference_prompt_compiler.py`

方法：

1. 文本解析 → 结构化slots（anatomy, side, finding_type, target_form, level）
2. Atlas空间先验（硬编码的解剖位置映射）
3. 结构化相似度检索（anatomy=4分, side=2分, finding_type=2分, level=2分）
4. Alpha混合atlas先验和检索先验
5. 按目标类型路由：focal/diffuse/bony/multifocal不同后处理

结果：Mean Dice = **0.0235**，0/91 Dice≥0.5

失败原因：与Exp4相同 — **空间坐标在不同患者间不可迁移。** npy volume经过不同裁剪/缩放，"右肾"在不同患者的像素空间中位置完全不同。

Exp4-5 的关键教训

> **文本无法在不看图像的情况下映射到像素坐标。** 任何text-only → spatial的方法（检索、atlas、规则）在这个数据格式下注定失败。解决方案必须涉及**联合text-image推理**：模型必须同时看到图像和理解文本。

Exp6 & Exp7: MedCLIP-SAMv2 (BiomedCLIP + M2IB → bbox → MedSAM)

脚本：`inference_medclip_medsam.py`

这是第一个真正做联合text-image推理的方案。

架构与原理

```
Text ("右侧腹股沟区肿块")
       ↓
  BiomedCLIP Text Encoder → text features (512-dim)
       ↓                          ↓
  BiomedCLIP Vision Encoder    cos_similarity
  (224×224 CT slice)               ↓
       ↓                    loss = β×compression - fitting
  M2IB Information Bottleneck
  (在ViT第7层插入可学习mask,
   10步梯度优化)
       ↓
  Saliency Map (224×224 热力图)
       ↓
  二值化 → Bounding Box
       ↓
  Scale到原始分辨率 → MedSAM → 分割mask
```

核心机制 — M2IB（Multi-Modal Information Bottleneck）：

- 在ViT的某一层插入一个可学习的mask（alpha参数）
- 通过sigmoid将alpha转为[0,1]的"通过率"lambda
- 目标函数：最大化text-image余弦相似度，同时最小化信息流量
- 优化10步后，alpha的分布就反映了图像中哪些patch对当前文本最重要
- 最终从alpha提取saliency map → 二值化 → bbox

实现过程与bug修复

模型加载:

- 最初使用 `open_clip` 加载BiomedCLIP base → saliency map完全均匀（mean=0.6，不区分文本）
- 下载DHN-NCE fine-tuned权重（784MB）→ 发现权重是HuggingFace格式，与open_clip不兼容
- **最终方案**：直接用 `AutoModel.from_pretrained("MedCLIP-SAMv2/saliency_maps/model", trust_remote_code=True)` 加载HF格式模型
- 修复了 `modeling_biomed_clip.py` 中 `from transformers.models.clip.modeling_clip import *` 在新版transformers中的导入问题

Wrapper重构:

- 移除了6个自定义wrapper类（VisionEmbeddings, ImageEncoderWrapper, TextEmbeddings, TextEncoderWrapper, BiomedCLIPWrapper, permute_then_forward）
- HF模型原生支持IBA所需的所有接口：
  - `model.vision_model(img, output_hidden_states=True)` → hidden_states
  - `model.get_text_features(text_ids)` → 512-dim features
  - `model.get_image_features(pixel_values)` → 512-dim features
  - `model.vision_model.encoder.layers[i]` → 可被replace_layer替换

之前在open_clip wrapper上修复的6个bug（已被重构淘汰）：

1. `TypeError: 'Embedding' object is not subscriptable` — BiomedCLIP的pos_emb是nn.Embedding
2. `AttributeError: 'BertLayer' has no attribute 'attn'` — BERT层属性名不同于ViT
3. `AttributeError: 'tuple' object has no attribute 'clone'` — InformationBottleneck返回tuple
4. `TypeError: unsupported operand @ for Sequential` — text_projection是Sequential不是矩阵
5. `RuntimeError: size mismatch 768 vs 512` — 返回了hidden state而非projected output
6. Saliency map均匀 — 使用base BiomedCLIP而非fine-tuned

实验结果

Exp6（无slice过滤，3 cases）：

case	target	GT voxels	Pred voxels	Dice
s0000	腹股沟肿块	9,913	226,168	0.049
s0000	盆腔淋巴结	461	276,282	0.002
s0001	胆囊窝结节	0	474,321	0.0
s0002	颈椎低密度结节	62	618,351	0.0

Mean Dice = **0.0073**。严重过分割：每个slice都生成bbox，pred远超gt。

诊断:

- 每个slice都有saliency响应 → 32/32 slices都产生bbox
- BiomedCLIP无法判断哪些slice包含目标

Exp7（加入slice聚焦度过滤，5 cases）：

改进：按saliency聚焦度 `focus = peak × (1 - coverage)` 排序，只保留top一半slice。

case	target	GT voxels	Pred voxels	Slices	Dice
s0000	腹股沟肿块	9,913	79,854	16	0.060
s0003	颈椎曲度反弓	12,338	34,470	16	**0.236**
s0004	肝缘不规则(肝硬化)	45,600	199,082	16	0.086
s0004	脾大	34,142	136,153	16	0.000

Mean Dice = **0.0284**。大面积弥漫性目标（颈椎病0.24）有一定效果，小目标仍然失败。

Saliency map质量分析

对同一slice测试不同文本query的saliency：

文本	Mean	>0.5覆盖率	BBox (224空间)
"右侧腹股沟肿块"	0.240	4.2%	[108,85,143,111] (小)
"盆腔淋巴结"	0.312	10.6%	[82,77,156,114] (中)
"正常肝实质"	0.315	9.6%	[75,76,155,111] (中)

Saliency有一定区分度（不同文本产生不同热力图），但不够精确。

CLS级别slice排序测试

测试用全局cosine similarity在32个slice中定位目标slice：

- **腹股沟肿块（11个GT slice）**：Top-10中命中9个（recall=82%），效果好
- **盆腔淋巴结（3个GT slice）**：Top-10中只命中1个（recall=33%），效果差

结论：大/明显的病变可以定位，小/散在的病变无法定位。

---

4. 失败分析总结

4.1 过分割是主要失败模式

Oracle bbox下：46%目标预测量>GT的3倍。

4.2 按目标大小的表现（Oracle bbox）

GT大小	数量	Mean Dice	过分割比
< 50 voxels	12	0.329	5.3x
50 - 500	26	0.469	4.1x
500 - 5K	31	0.422	3.8x
5K - 50K	12	0.756	1.4x
> 50K	2	0.601	2.6x

4.3 三种text-guided方法失败的根本原因

方法	失败原因
TF-IDF检索	词袋相似度无法映射空间位置
Prompt Compiler	Atlas先验在不同裁剪/缩放的npy间不可迁移
MedCLIP-SAMv2	BiomedCLIP是2D模型，CT切片与训练数据差异大；saliency太散；无法判断目标在哪些slice上

共同根因：在不训练的条件下，没有模型能同时理解（1）医学文本的语义（2）CT切片的空间解剖（3）两者之间的对应关系。

---

5. 下一步方案调研

方案一：M3D-LaMed（⭐推荐优先级最高）

来源：BAAI（智源研究院），2024年4月发布

架构：

- 3D视觉编码器（CLIP策略预训练，12万image-text对）
- 3D空间池化感知器（压缩3D token序列）
- LLM骨干：LLaMA-2-7B 或 Phi-3-4B（轻量版）
- SegVol分割模块：通过`[SEG]`token触发3D mask生成

为什么推荐：

- **M3D-RefSeg就是它的benchmark** — 数据格式完全匹配 (1×32×256×256 npy)
- 不需要任何数据转换，直接推理
- 原生支持自由文本 → 3D分割
- 有Phi-3-4B轻量版，12GB fp16可能够用

代码/权重：

- GitHub: `BAAI-DCAI/M3D`
- HuggingFace: `GoodBaiBai88/M3D-LaMed-Phi-3-4B`
- Apache 2.0开源

显存：7B版本fp16约14GB（偏紧），4B版本推荐

方案二：SegVol

来源：BAAI，NeurIPS 2024

架构：

- 3D ViT编码器（SimMIM预训练，9.6万CT）
- CLIP文本编码器（冻结）
- Prompt编码器（点/框/文本）
- Mask解码器（交叉注意力融合）
- Zoom-Out-Zoom-In推理机制

特点：

- 支持200+解剖结构
- 文本prompt限于标准解剖学术语（"liver"、"kidney"），非自由文本
- 需从描述中提取关键词

代码/权重：

- GitHub: `BAAI-DCAI/SegVol`
- HuggingFace: `BAAI/SegVol`
- 输入格式支持 npy、NIfTI、DICOM

方案三：BiomedParse v2

来源：Microsoft Research，发表于Nature Methods 2025

架构：

- BoltzFormer架构
- 600万 image-mask-text 三元组训练
- 82种目标类型，9种影像模态
- v2新增3D支持（逐slice+邻近context编码为RGB）

特点：

- 原生支持text-guided分割
- 文本prompt比bbox更好用
- 支持CT、MR、PET、超声、病理等

局限：

- 逐slice处理3D（和MedCLIP-SAMv2类似）
- 显存需求≥16GB
- 环境搭建复杂（Python 3.10.14, CUDA 12.4）

代码/权重：

- GitHub: `microsoft/BiomedParse`
- HuggingFace: `microsoft/BiomedParse` (biomedparse_v2.ckpt)

方案四：Fine-tune BiomedCLIP

目标：在现有MedCLIP-SAMv2框架下，用M3D-RefSeg数据fine-tune BiomedCLIP，提升saliency map质量。

方法：

- DHN-NCE对比学习loss（代码已有：`MedCLIP-SAMv2/biomedclip_finetuning/`）
- 或 LoRA低秩适配（参数减少99.5%，12GB够用）
- 784个text-image对超过最低可行阈值（200-300）

训练配置：

```
batch_size=16, epochs=32~50, lr=2e-4
LoRA: rank=16, alpha=32
DHN-NCE: temperature=0.6, beta1=beta2=0.15
```

预计时间：RTX 4070上 4-8小时

预期效果：

- Saliency map从覆盖30-50% → 缩小到更聚焦区域
- 但仍是2D逐slice方案，无法解决"目标在哪些slice"的问题
- 预估Dice可能从0.03提升到0.05-0.10

方案对比

	M3D-LaMed	SegVol	BiomedParse v2	Fine-tune BiomedCLIP
数据兼容	完美（专用）	需适配	需转格式	需转2D
3D原生	✅	✅	❌（逐slice）	❌（逐slice）
自由文本	✅	❌（关键词）	✅	✅
12GB可行	4B版勉强	需测试	可能不够	✅（LoRA）
部署难度	低（pip）	中	高	中（需训练）
需要训练	❌	❌	❌	✅（4-8h）
预期效果	最高	中高	高	中

---

6. 文件结构

```
D:/M3D/
├── inference_medsam_refseg.py              # Exp1-2: MedSAM oracle bbox推理
├── inference_medsam_improved.py            # Exp3: 推理tricks消融
├── inference_medsam_retrieval.py           # Exp4: TF-IDF文本检索→bbox→MedSAM
├── inference_medclip_medsam.py             # Exp6-7: MedCLIP-SAMv2 pipeline
├── project_status.md                       # 本文档
├── plan.md                                 # 用户提供的改进路线图
|
├── MedSAM/                                 # MedSAM仓库
|   ├── segment_anything/                   # SAM模型代码
|   └── work_dir/
|       ├── MedSAM/medsam_vit_b.pth               # SAM ViT-B原始权重 (358MB)
|       └── MedSAM_finetuned/medsam_vit_b.pth     # MedSAM fine-tuned权重 (375MB)
|
├── MedCLIP-SAMv2/                          # MedCLIP-SAMv2仓库
|   ├── saliency_maps/
|   |   ├── model/                          # BiomedCLIP HF模型 + fine-tuned权重
|   |   |   ├── pytorch_model.bin           # DHN-NCE fine-tuned权重 (784MB)
```

```
|   |   |   ├── modeling_biomed_clip.py     # 自定义HF模型定义
|   |   |   └── config.json
|   |   ├── scripts/                        # IBA/M2IB原始代码
|   |   └── generate_saliency_maps.py       # 原始saliency生成脚本
|   └── biomedclip_finetuning/              # BiomedCLIP fine-tuning代码
|
├── experiments/                            # Exp5: Prompt Compiler实验
|   ├── scripts/
|   |   ├── prompt_compiler/                # 编译器代码 (compiler.py, retrieval.py)
|   |   └── inference_prompt_compiler.py    # 推理脚本
|   ├── results/
|   └── README.md
|
├── M3D_RefSeg_npy/                         # 数据集 (208 cases, .gitignored)
|   ├── s0000/ {ct.npy, mask.npy, text.json}
|   └── ...
|
├── results_medsam/                         # Exp1结果 (SAM权重, 50 cases)
├── results_medsam_ft/                      # Exp2结果 (MedSAM权重, 30 cases)
├── results_medsam_improved/                # Exp3结果 (tricks消融, 30 cases)
├── results_medsam_retrieval/               # Exp4结果 (TF-IDF检索, 30 cases)
├── results_medclip_medsam/                 # Exp6结果 (MedCLIP-SAMv2 v1, 3 cases)
└── results_medclip_medsam_v2/              # Exp7结果 (MedCLIP-SAMv2 v2, 5 cases)
```

---

7. 技术笔记

MedSAM vs CLIP 的本质区别

- **MedSAM (SAM)**：纯视觉模型，接受视觉prompt（bbox/point/mask）→ 分割mask。**没有文本理解能力。**
- **CLIP/BiomedCLIP**：视觉-语言对齐模型，将图像和文本映射到同一embedding空间。**有文本理解但没有分割能力。**
- **MedCLIP-SAMv2**：用CLIP做text-image对齐 → 生成saliency → 转为bbox → 送入SAM分割。桥接两者。

M2IB Information Bottleneck 原理

1. 在ViT的第k层（默认layer=7）插入一个可学习的mask α（shape同hidden state）
2. 通过sigmoid(α)得到"通过率"λ∈[0,1]
3. 原始hidden state × λ = 被mask后的表示
4. 优化目标：`loss = β × compression - cos_sim(text, image)`
    - compression = KL散度，衡量信息流量
    - cos_sim = 文本和图像特征的余弦相似度
5. 10步Adam优化后，α的分布反映了哪些patch对当前文本最重要

数据格式核心问题

M3D-RefSeg的npy volume (1, 32, 256, 256) 是经过**per-patient裁剪和缩放**的：

- 不同患者的相同解剖结构在像素空间中位置不同
- 没有统一的世界坐标系
- 因此任何"从文本推断像素坐标"的方法都会失败
- 必须**看图像**才能定位